Projet Final - Fouille de Données Massives

CASANOVA MARROQUIN Stephanya

03/12/2021

Données

Le projet a été basé sur une base de données décrivant **6224 individus américains** décrits par 15 variables:

- **Age** : âge
- **CSP** : catégorie socio-professionnelle
- **ScoreDemo** : un score démographique
- **Diplome** : le type de diplôme
- **ScoreDiplome** : un score construit en fonction du type de diplôme
- **StatutMarital** : le statut marital
- **Profession** : la profession
- **SituationFamiliale** : la situation familiale
- **Ethnie** : l'origine ethnique
- **Genre** : le genre
- **Economies** : le montant des économies
- **Dettes** : le montant des dettes
- **HeureSemaine** : le nombre d'heures travaillées par semaine
- **PaysOrigine** : le pays d'origine
- **Revenus** : montant des revenus (supérieur ou inférieur à 50k$)

Import des données dans notre environnement

Pour charger les données dans notre environnement, nous allons utiliser le commande :

```
data = read.table("adult_sample.data",sep=",",header=TRUE,
                  strip.white=TRUE,na.strings ="?",
                  stringsAsFactors = TRUE)
```

Dans ce commande nous pouvons observer les parameters **sep** : référence au séparateur, **strip.white** : supprime les espaces en blanc après d'un séparateur, **na.strings**: sustitution d'un string pour NA et **stringsAsFactors**.

Travail effectué

1. Identification des valeurs nulls et imputation des valeurs : Après d'avoir importé les données, nous allons identifier les valeur nulls et nous allons les imputer une valeur par defaut. Initialement, nous identifions les variables catégorielles et quantitatives :

```
ind_categ_feature = c(2,4,6,7,8,9,10,14,15)
data_categ = data[, ind_categ_feature]
data_continuous = data [,-ind_categ_feature]
```

Avec le commande **summary()** nous allons regarder les détails des données :

```
summary(data_categ)
```

```
##                CSP               Diplome                   StatutMarital
##  Private         :4301   HS-grad     :2003   Divorced              : 850
##  Self-emp-not-inc: 489   Some-college:1418   Married-AF-spouse     :   5
##  Local-gov       : 400   Bachelors   :1020   Married-civ-spouse    :2848
##  State-gov       : 242   Masters     : 324   Married-spouse-absent:  86
##  Self-emp-inc    : 229   Assoc-voc   : 271   Never-married         :2051
##  (Other)         : 175   11th        : 231   Separated             : 194
##  NA's            : 388   (Other)     : 957   Widowed               : 190
##            Profession        SituationFamiliale                Ethnie
##  Craft-repair    : 783   Husband       :2499     Amer-Indian-Eskimo:  63
##  Exec-managerial: 766   Not-in-family :1603     Asian-Pac-Islander: 189
##  Prof-specialty : 766   Other-relative: 188     Black             : 617
##  Sales           : 735   Own-child     : 972     Other             :  45
##  Adm-clerical    : 714   Unmarried     : 646     White             :5310
##  (Other)         :2071   Wife          : 316
##  NA's            : 389
##     Genre             PaysOrigine    Revenus
##  Female:2025   United-States:5561   <=50K:4715
##  Male  :4199   Mexico       : 126   >50K :1509
##                Canada       :  34
##                Germany      :  28
##                Philippines  :  28
##                (Other)      : 326
##                NA's         : 121
```

Dans cette information, nous pouvons observer que les variables **CSP, Profession et PaysOrigine** ont des valeurs **nulls**.

```
attWithNA<-subset(data_categ, select=c(CSP, Profession, PaysOrigine))
summary(attWithNA)
```

```
##                CSP                Profession          PaysOrigine
##  Private         :4301   Craft-repair    : 783   United-States:5561
##  Self-emp-not-inc: 489   Exec-managerial: 766   Mexico       : 126
##  Local-gov       : 400   Prof-specialty  : 766   Canada       :  34
##  State-gov       : 242   Sales           : 735   Germany      :  28
##  Self-emp-inc    : 229   Adm-clerical    : 714   Philippines  :  28
```

```
##  (Other)          : 175   (Other)         :2071   (Other)       : 326
##  NA's             : 388   NA's            : 389   NA's          : 121
```

Ces valeurs nulls vont être remplacés par de valeurs aléatoires en fonction de la distribution de fréquences dans chaque attribut :

```
naCSP=length(data_categ$CSP[is.na(data_categ$CSP)])
data_categ$CSP[is.na(data_categ$CSP)]=sample(levels(data_categ$CSP),naCSP,
prob=table(data_categ$CSP),replace=TRUE)
data_categ$CSP=as.factor(data_categ$CSP)

nbNA=length(data_categ$Profession[is.na(data_categ$Profession)])
data_categ$Profession[is.na(data_categ$Profession)]=sample(levels(data_categ$Profession),nbNA,
prob=table(data_categ$Profession),replace=TRUE)
data_categ$Profession=as.factor(data_categ$Profession)

nbNA=length(data_categ$PaysOrigine[is.na(data_categ$PaysOrigine)])
data_categ$PaysOrigine[is.na(data_categ$PaysOrigine)]=sample(levels(data_categ$PaysOrigine),nbNA,
prob=table(data_categ$PaysOrigine),replace=TRUE)
data_categ$PaysOrigine=as.factor(data_categ$PaysOrigine)
```

De nouveau **Summary** pour valider que effectivement les donnés ont été replacés :

```
attWithNA<-subset(data_categ, select=c(CSP, Profession, PaysOrigine))
summary(attWithNA)
```

```
##                CSP                 Profession          PaysOrigine
##  Private         :4588   Craft-repair   : 832   United-States:5671
##  Self-emp-not-inc: 523   Prof-specialty : 816   Mexico       : 126
##  Local-gov       : 426   Exec-managerial: 814   Canada       :  36
##  State-gov       : 261   Sales          : 776   Philippines  :  30
##  Self-emp-inc    : 241   Adm-clerical   : 761   Germany      :  28
##  Federal-gov     : 183   Other-service  : 668   Puerto-Rico  :  22
##  (Other)         :   2   (Other)        :1557   (Other)      : 311
```

Maintenant, nous allons observer les détails des attributs quantitatives :

```
summary(data_continuous)
```

```
##       Age          ScoreDemo        ScoreDiplome     Economies
##  Min.   :17.00   Min.   :  19302   Min.   : 1.00   Min.   :    0
##  1st Qu.:28.00   1st Qu.: 118253   1st Qu.: 9.00   1st Qu.:    0
##  Median :37.00   Median : 179312   Median :10.00   Median :    0
##  Mean   :38.62   Mean   : 191041   Mean   :10.06   Mean   : 1028
##  3rd Qu.:48.00   3rd Qu.: 241204   3rd Qu.:12.00   3rd Qu.:    0
##  Max.   :90.00   Max.   :1184622   Max.   :16.00   Max.   :99999
##      Dettes         HeureSemaine
##  Min.   :   0.00   Min.   : 1.00
##  1st Qu.:   0.00   1st Qu.:40.00
##  Median :   0.00   Median :40.00
##  Mean   :  89.81   Mean   :40.48
##  3rd Qu.:   0.00   3rd Qu.:45.00
##  Max.   :3004.00   Max.   :99.00
```

Dans les résultat, nous ne trouvons pas des valeurs nulls.

Nous allons supprimer la variable redondante ScoreDiplome puisque est le recodage de la variable Diplome :

```
data_continuous$ScoreDiplome = NULL
```

2. Analyse Factorielle : Maintenant avec la data traitée, nous allons faire une analyse en composant principals sur les variables continues :

```
res.pca <- PCA(data_continuous, graph = FALSE)
fviz_eig(res.pca, addlabels = TRUE)
```

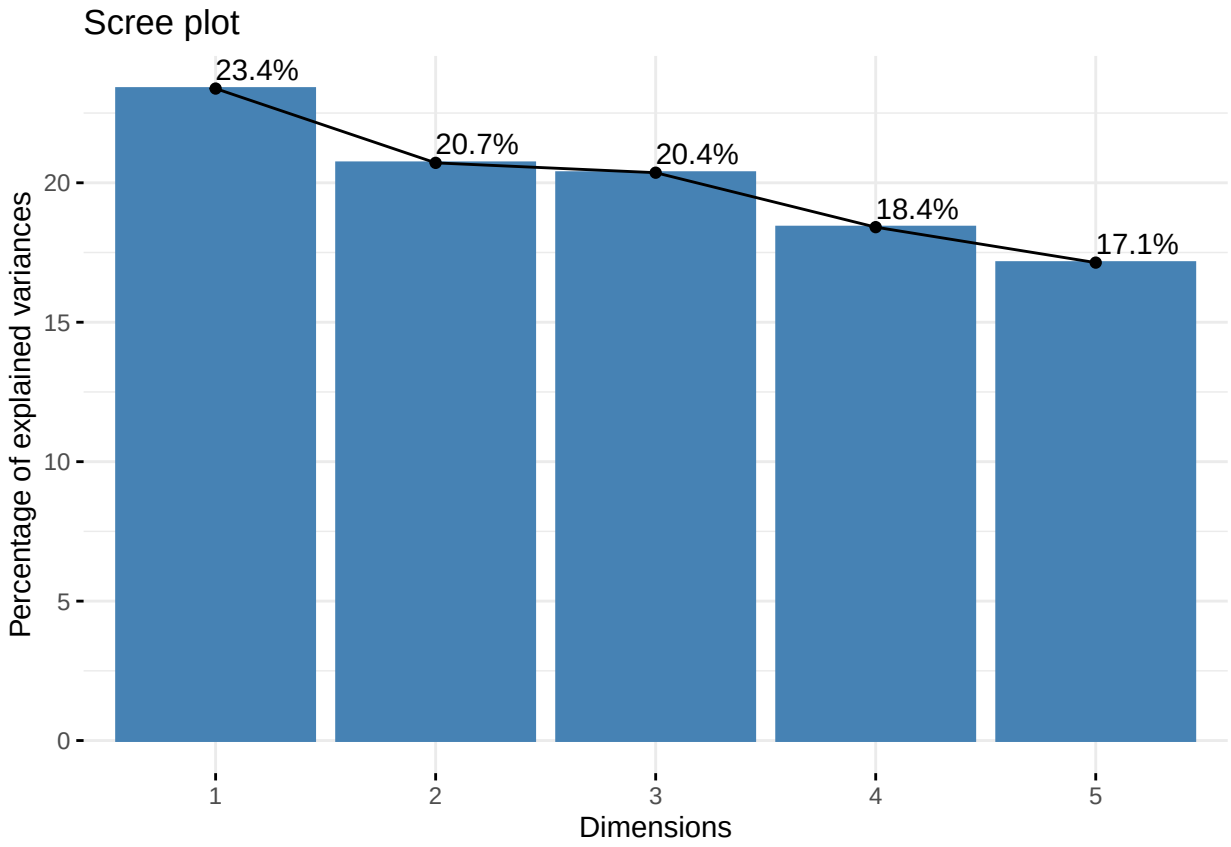

Du graphique ci-dessus, nous observons que le 82.9% ($> 72\%$) des informations (variances) contenues dans les données sont conservées par les quatre premières composantes principaux.

```
# Colorer en fonction du cos2: qualité de représentation
fviz_pca_var(res.pca, col.var = "cos2",
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
             repel = TRUE # Évite le chevauchement de texte
             )
```

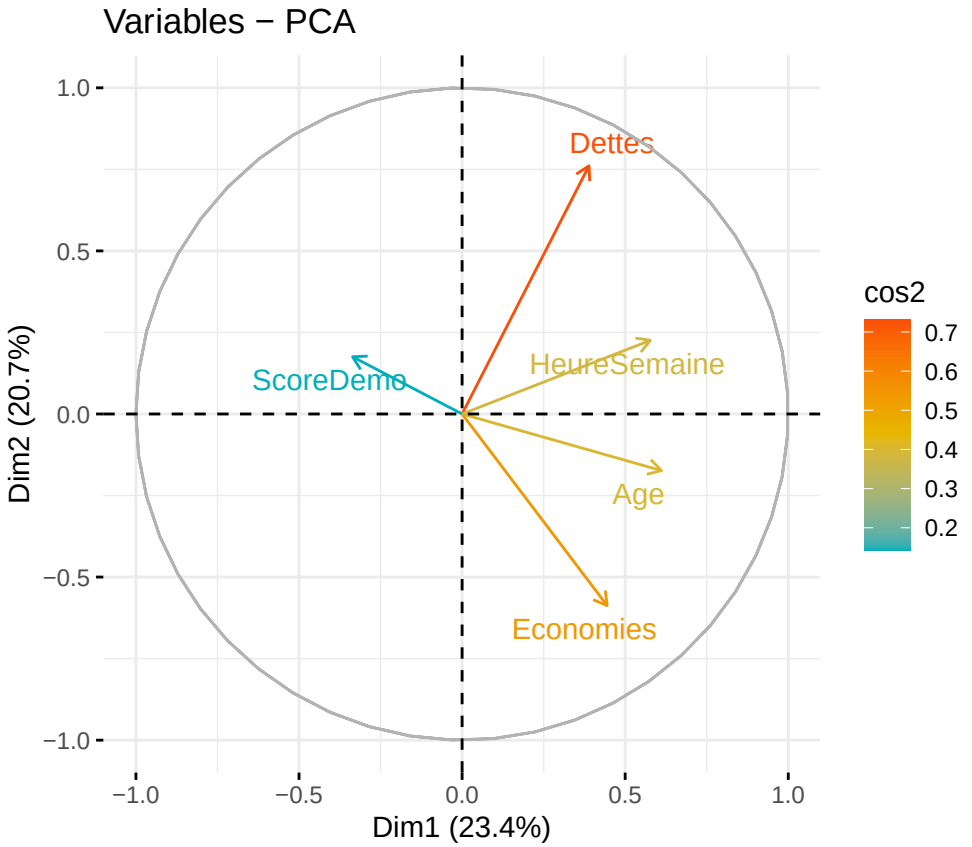

Le graphique de corrélation des variables ci-dessus montre les relations entre toutes les variables. Il peut être interprété comme suit:
* Les variables : **Dettes et HeureSemaine** et **Age et Economies** sont positivement corrélées.
* Les variables : **ScoreDemo et (Age, Economies)** sont négativement corrélées.
* Les variables **ScoreDemo, Age et HeureSemaine** ne sont pas bien représentés pour l'ACP (cos2) à différence de **Dettes et Economies**

Maintenant, nous allons regarder la contribution de chaque variable aux axes principaux :

```
res.pca$var$contrib
```

```
##                 Dim.1     Dim.2       Dim.3       Dim.4     Dim.5
## Age          31.965557  2.908096  7.80407230 40.28041948 17.041856
## ScoreDemo     9.649666  2.974066 56.24750717 26.77278503  4.355976
## Economies    16.927830 33.315762 19.02590595  0.09252983 30.637973
## Dettes       12.944193 55.874475  0.04812468  4.30854503 26.824662
## HeureSemaine 28.512754  4.927602 16.87438990 28.54572063 21.139533
```

Maintenant, pour les individus :

```
fviz_pca_ind(res.pca)
```

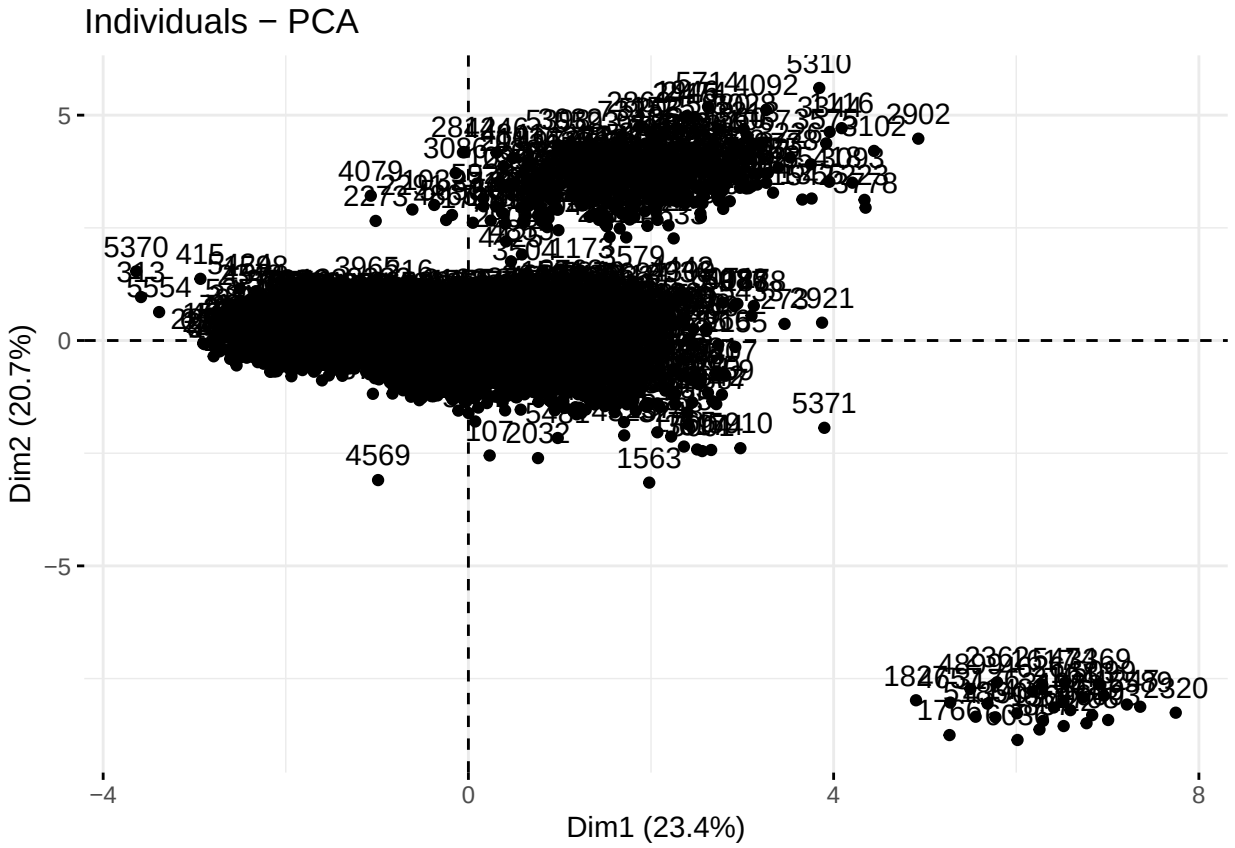

Le graphique ci-dessus permet observer le comportement de chaque individu en considérant les variables : **age, economies, heureSemaine, dettes et scoreDemo**. Nous pouvons observer alors les gens ayant le plus de dettes et les plus d'heures travaillées en haut et les gens qui ont plus des economies et d'âge en bas. Le groupe en bas à droite représente un groupe avec des économies et des revenus élevés. Ces individus vont être mis de côté pour l'analyse.

```
data_categ$Economies = data_continuous$Economies
data_continuous<-filter(data_continuous, Economies != 99999)
data_categ<-filter(data_categ, Economies != 99999)
data_categ$Economies = NULL
res.pca <- PCA(data_continuous, graph = FALSE)
fviz_eig(res.pca, addlabels = TRUE)
```

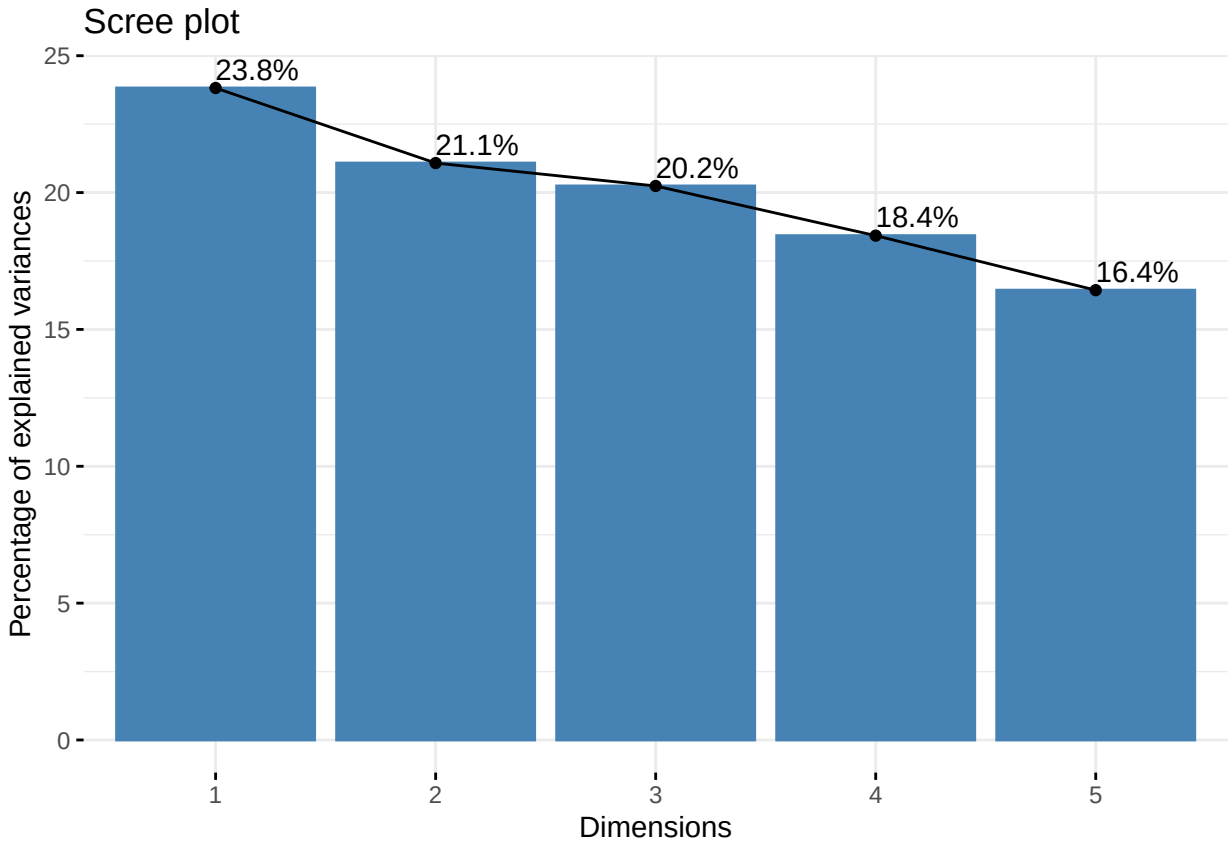

Après d'avoir filtrés les individus avec **Economies** de 99999 :

```
fviz_pca_var(res.pca, col.var = "cos2",
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
             repel = TRUE # Évite le chevauchement de texte
             )
```

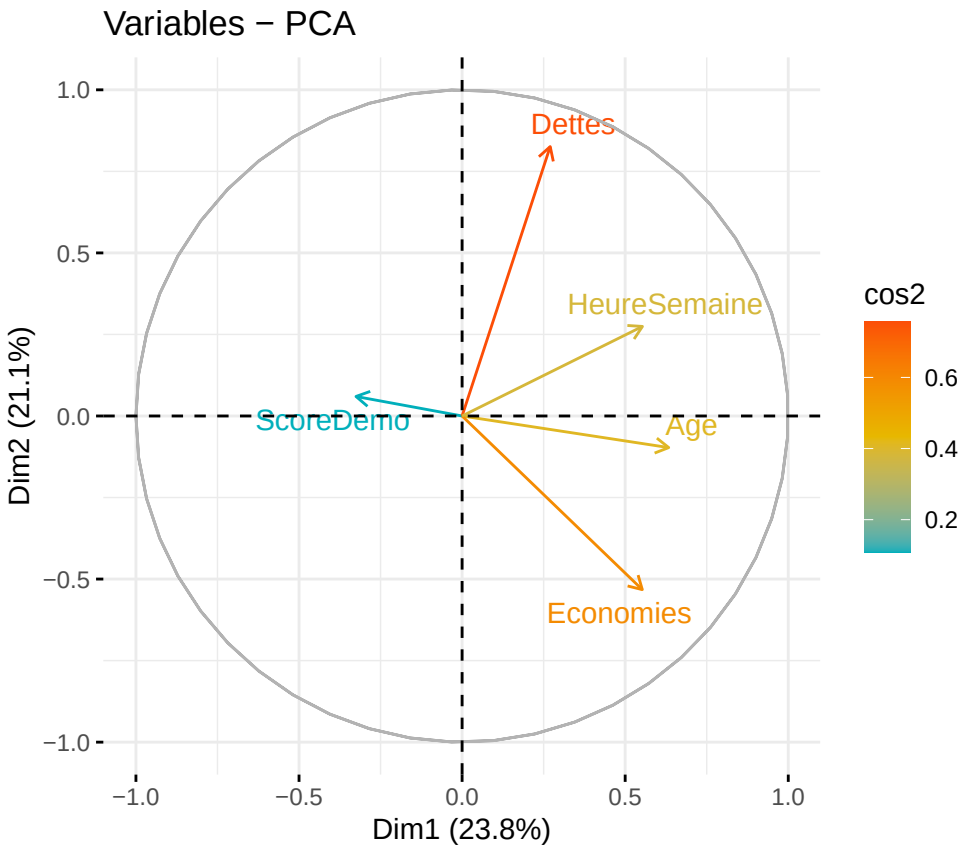


```
fviz_pca_ind(res.pca)
```

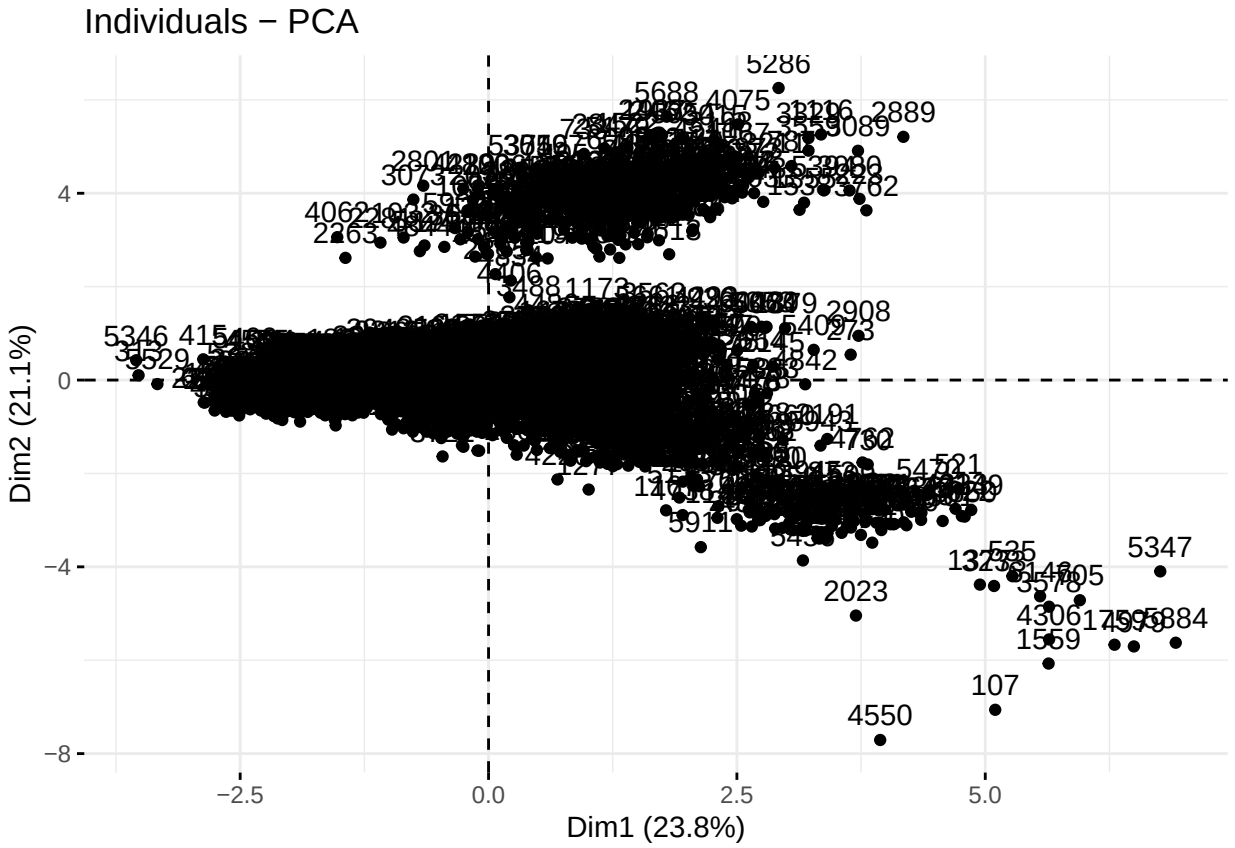

3. Clustering : Comme les unités de mesure sont très différentes, nous allons normaliser les données :

```
data_continuous2=scale(data_continuous)
```

Maintenant, nous allons utiliser l'inertie intra-classe pour choisir un nombre de clusters adéquat :

```
inertie=c()
for (k in 1:10){
res=kmeans(data_continuous2,centers=k,nstart = 10)
inertie[k]=res$tot.withinss
}
plot(1:10,inertie,type='l')
```

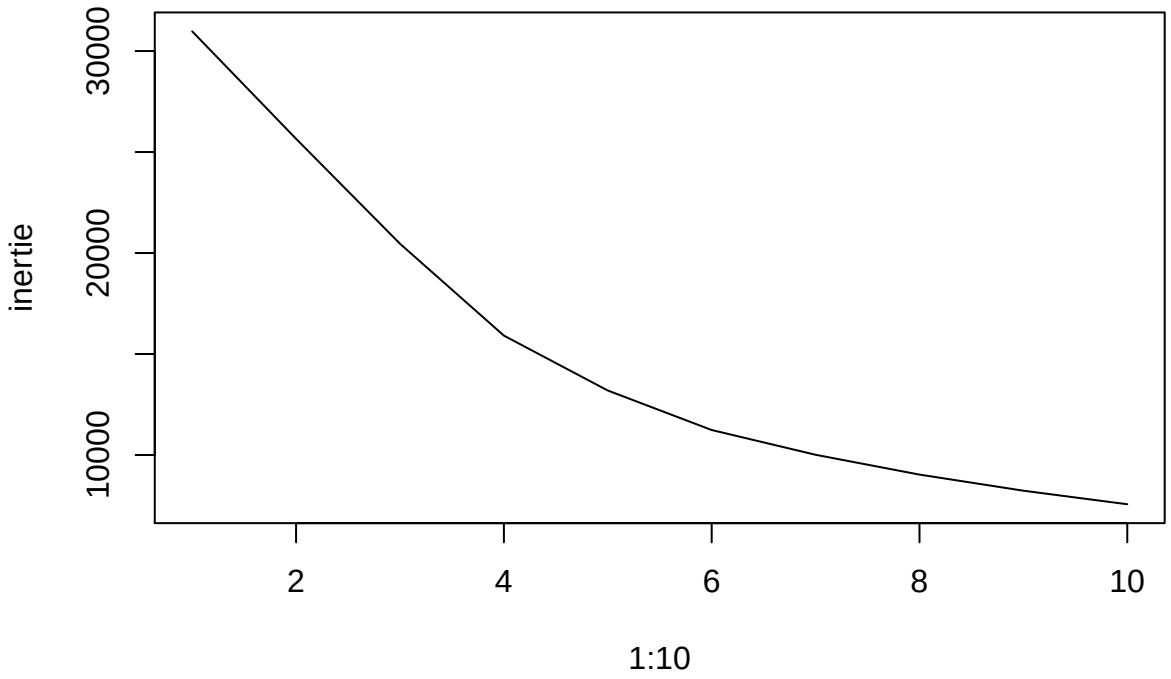

Selon le graphique, nous allons choisir 4 clusters.

```
res_ka=kmeans(data_continuous2,centers=4,nstart = 10)
res.pca <- PCA(data_continuous2, graph = FALSE)
plot(res.pca,choix = "ind",col.ind = res_ka$cluster,graph.type = "classic")
```

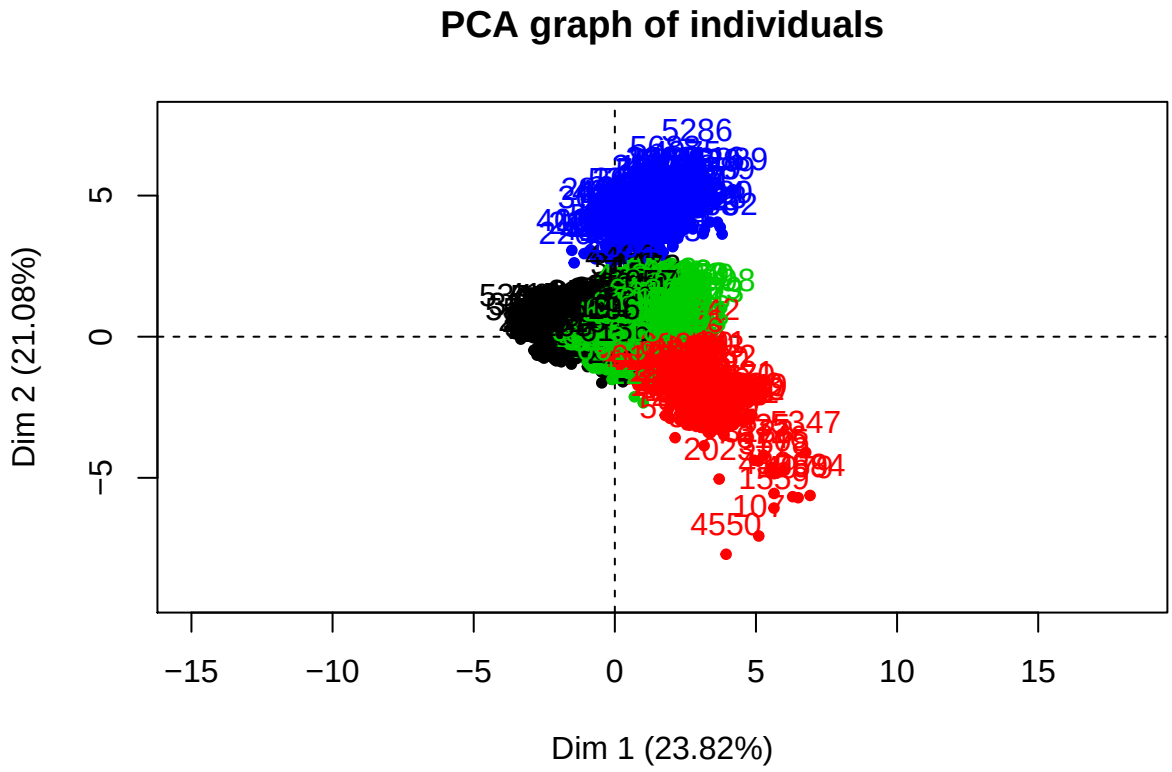

Ces 4 clusters pourraient correspondre à :
* **Cluster axe 1 centre** = Les gens qui travaillent le plus
* **Cluster axe 1 en haut** = Les gens avec plus de dettes

* **Cluster axe 2 centre** = Les gens avec le scoreDemo plus haut
* **Cluster axe 4** = Les gens avec plus des economies et agés

```
plot(res.pca,choix = "var",graph.type = 'classic')
```

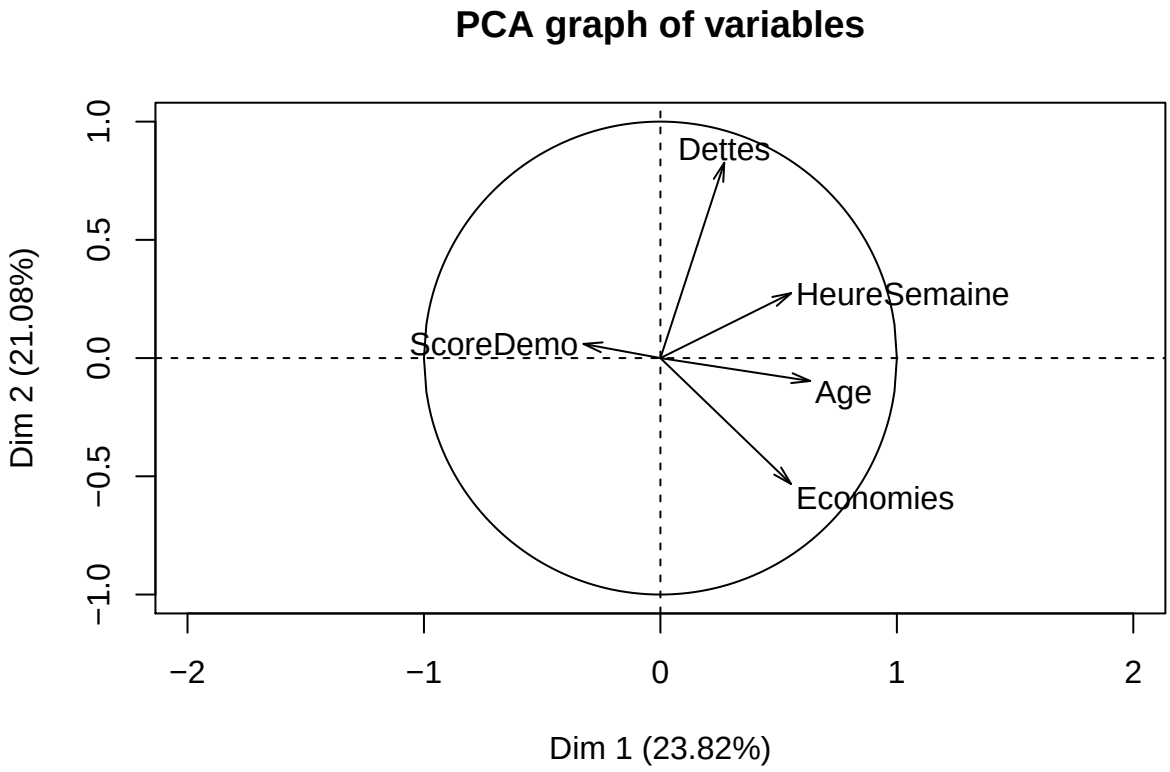

4 Prediction

4.1 Ensemble d'entraînement et de testing : Pour la base de test, nous allons prendre 1000 individus au hasard :

```
set.seed(1)
ind_test=sample(1:nrow(data_continuous),1000)
dco_test=data_continuous[ind_test,]
dco_app=data_continuous[-ind_test,]
dca_test=data_categ[ind_test,]
dca_app=data_categ[-ind_test,]
```

4.2 Arbre de clasification : Pour la classification, nous allons utiliser un arbre binaire sur les données quantitatives. Il faut alors utiliser un dataframe et rapatrier la variable à prédire **Revenus** dans le même dataframe que les variables quantitatives :

```
dfco_app=data.frame(dco_app,Revenus=dca_app$Revenus)
mod2=rpart(Revenus~.,data=dfco_app)
p=predict(mod2,newdata = dco_test,type='class')
fancyRpartPlot(mod2,caption=NULL)
```

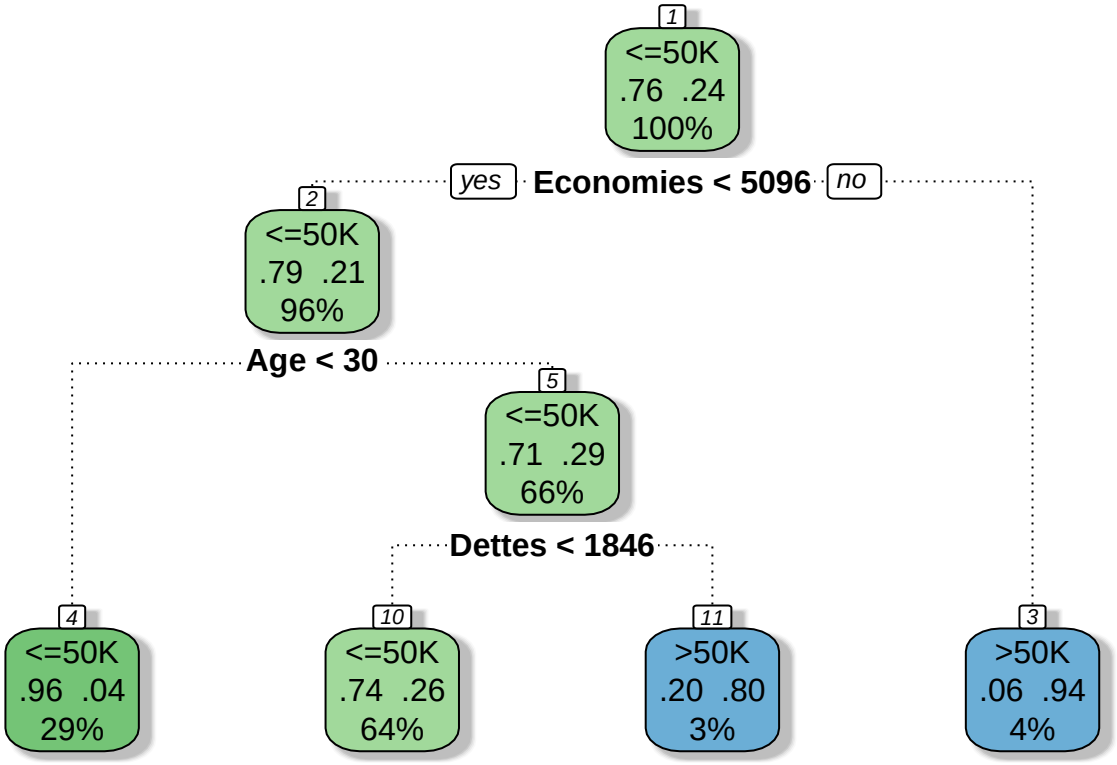

Pour évaluer les performances de l'arbre, nous allons observer le taux de bon classement et la matrice de confusion :

```
mean(p==dca_test$Revenus)
```

```
## [1] 0.831
```

```
table(p, dca_test$Revenus)
```

```
##
## p       <=50K >50K
##   <=50K   770  164
##   >50K      5   61
```

On constate que la qualité de la prédiction dépend beaucoup de la classe. En effet, sur les 934 individus qui ont revenus <= 50K, le taux de prévisions correctes est de 82.44 % environ, alors que sur les 66 individus avec >50K, il n'est que de 92.42 % environ.

Maintenant, si nous voudrions considérer toutes les variables quantitatives et catégorielles :

```
app=cbind(dco_app,dca_app)
test=cbind(dco_test,dca_test)
mod3=rpart(Revenus~.,data=app)
p=predict(mod3,newdata = test,type='class')
fancyRpartPlot(mod3,caption=NULL)
```

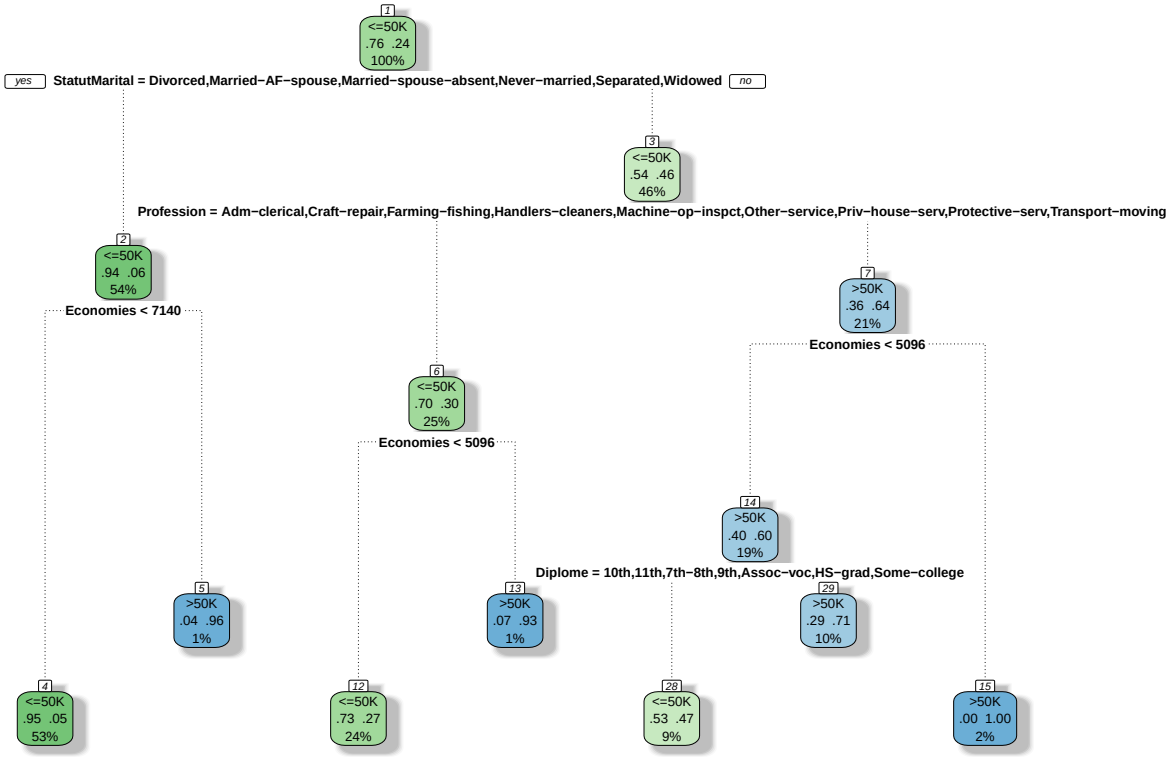

Taux de bon classement et la matrice de confusion :

```
mean(p==test$Revenus)
```

```
## [1] 0.841
```

```
table(p, test$Revenus)
```

```
##
## p       <=50K >50K
##   <=50K   742  126
##   >50K     33   99
```

4.3 Forêt aléatoire : Pour la classification avec une forêt aléatoire, nous allons observer l'impact des différentes variables dans la prédiction et nous allons modifier l'hyper-paramètre mtry pour obtenir une meilleur taux de classification.

```
set.seed(123)
mod4=randomForest(Revenus~.,data=app)
print(mod4)
```

```
##
## Call:
##  randomForest(formula = Revenus ~ ., data = app)
##                Type of random forest: classification
##                      Number of trees: 500
## No. of variables tried at each split: 3
##
##         OOB estimate of  error rate: 15.2%
## Confusion matrix:
##       <=50K >50K class.error
## <=50K  3634  306  0.07766497
```

```
## >50K    484  772  0.38535032
```

Dans la matrice de confusion, nous pouvons observer une meilleur classification pour la classe Revenus <=50K (8.09%) en comparaison à 38.69% d'erreur pour la classe >50K. Maintenant, nous allons observer quels sont les variables qui figurent dans notre modèle discriminant qui génèrent cette classification :

```
varImpPlot(mod4)
```

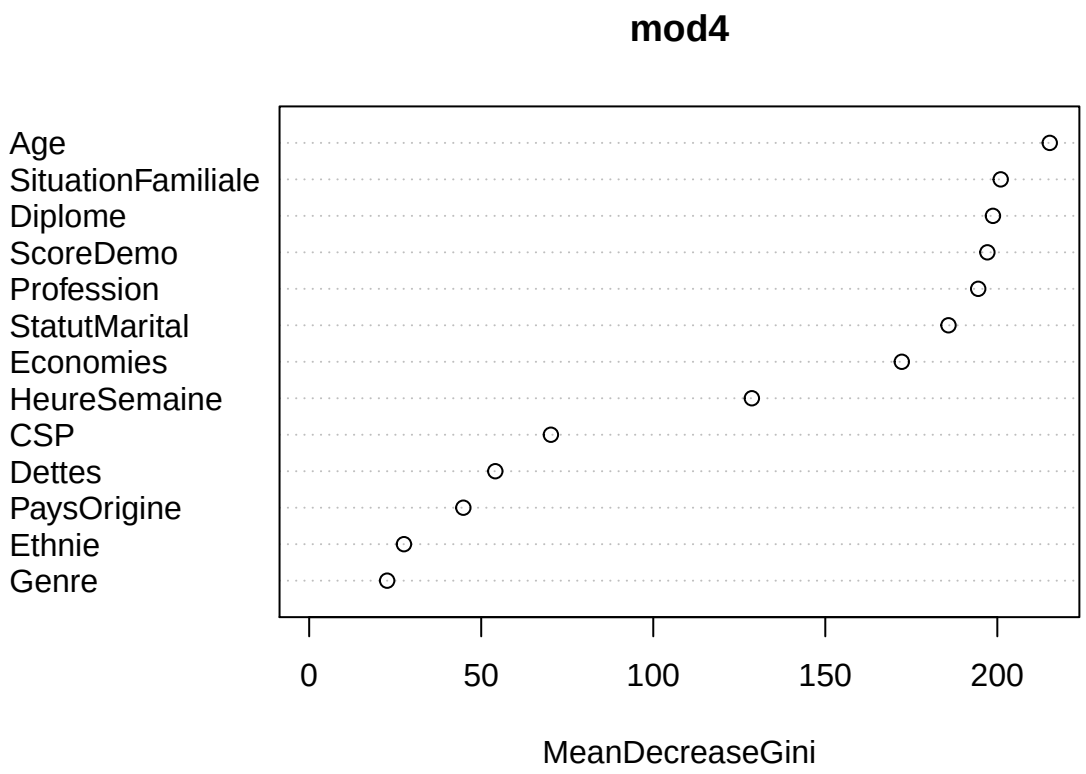

Dans le modèle que l'on a calculé, les 4 critères qui comptent le plus pour la classification sont **Age, Diplome, Profession et SituationFamiliale**.

Maintenant, si nous voulons améliorer la classification ou plus précisément minimiser **l'OOB** de 15.49% nous pourrons modifier 2 éléments : le nombre d'arbres construit par l'algorithme (**ntree = 500**) et le nombre e variables testées à chaque division (**mtry = 3**).

Si nous voudrions choisir l'autre valeur de nTree, il faudrait choisir un nTree lorsque la valeur se stabilise au minimum :

```
plot(mod4$err.rate[, 1], type = "l", xlab = "nombre d'arbres", ylab = "erreur OOB")
```

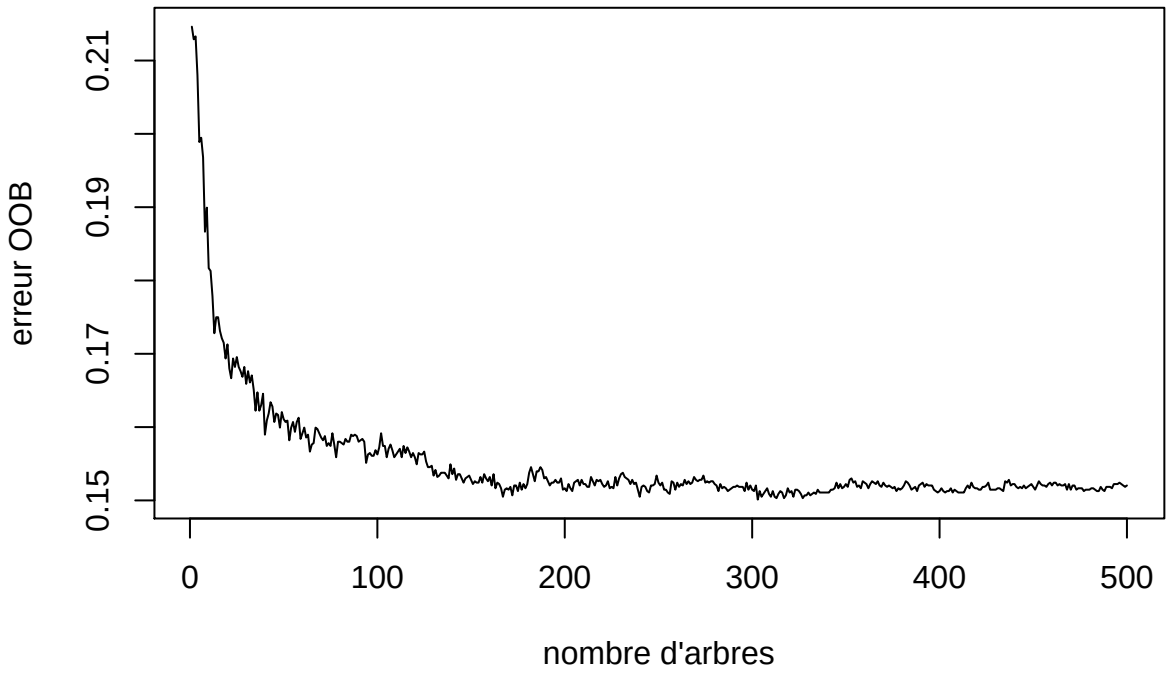

Pour choisir le mtry, nous avons fait tourner Random Forest 10 fois avec dix valeurs de mtry différentes et nous avons choisi celle pour laquelle le mtry est minimal et se stabilise **mtry = 2**:

```
set.seed(123)
mod4 <-randomForest(Revenus~.,data=app, mtry=2, importance=TRUE,ntree=500)
print(mod4)
```

```
##
## Call:
##  randomForest(formula = Revenus ~ ., data = app, mtry = 2, importance = TRUE,      ntree = 500)
##                Type of random forest: classification
##                      Number of trees: 500
## No. of variables tried at each split: 2
##
##         OOB estimate of  error rate: 14.63%
## Confusion matrix:
##       <=50K >50K class.error
## <=50K  3676  264  0.06700508
## >50K    496  760  0.39490446
```

L'OOB obtenu **14.57%** est mieux qu'avant **15.24%** en 4.39%.

Maintenant, si nous faisons la prédiction avec le modèle amélioré :

```
set.seed(123)
p=predict(mod4,newdata = test,type='class')
```

Nous obtenons un taux de bon classement et la matrice de confusion :

```
mean(p==test$Revenus)
```

```
## [1] 0.838
```

```
table(p, test$Revenus)
```

```
##
```

```
## p       <=50K >50K
##   <=50K   712   99
##   >50K     63  126
```

Références Mars 14 2021

http://www.sthda.com/french/wiki/fviz-pca-visualisation-de-l-analyse-en-composante-principale-logiciel-r-et-analyse-de-donn-es
http://mehdikhaneboubi.free.fr/random_forest_r.html
https://www.listendata.com/2014/11/random-forest-with-r.html